

把数据结构里增加图进去。

数据往往是一个高维的随机变量

$$p(x_1, x_2, \dots, x_p)$$

边缘概率 $p(x_i)$

图是用于表达的工县

条件概率 $p(x_j | x_i)$

Sum 求和 $p(x_1) = \int p(x_1, x_2) dx_2 \rightarrow$ 边缘概率

求积 $p(x_1, x_2) = p(x_1) \cdot p(x_2 | x_1) = p(x_2) \cdot p(x_1 | x_2)$

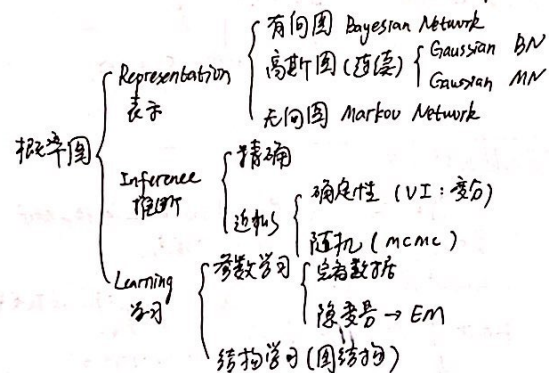
Chain Rule: $p(x_1, x_2, \dots, x_p) = \prod_{i=1}^p p(x_i | x_1, x_2, \dots, x_{i-1})$

Bayesian Rule: $p(x_2 | x_1) = \frac{p(x_1, x_2)}{p(x_1)} = \frac{p(x_1, x_2)}{\int p(x_1, x_2) dx_2} = \frac{p(x_2) \cdot p(x_1 | x_2)}{\int p(x_1, x_2) dx_2}$

困难: 维度高, 计算复杂. Chain Rule $p(x_1, x_2, \dots, x_p)$ 计算量太大 ▲

问: 相互独立. 那么 $p(x_1, x_2, \dots, x_p) = \prod_{i=1}^p p(x_i)$, 朴素贝叶斯 $\rightarrow p(x_i | y) = \prod_{i=1}^p p(x_i | y)$
(维度之间)

但是相互独立太强了, 使用子独立 (一阶) $x_j \perp x_{i+1} | x_i, j < i \rightarrow$ 条件独立性 $x_a \perp x_b | x_c$
(x_a, x_b, x_c 是节点, 且不相交)



概率图模型 - 贝叶斯网络 - 条件独立性 (2)

如何构建有向图? 拓扑排序. 若 $p(x_i | \text{父})$, 那么 $\text{父} \rightarrow \text{子}$, x_i 是 x_i 的父节点

① $a \rightarrow b, a \rightarrow c$
 $p(a, b, c) = p(a) \cdot p(b|a) \cdot p(c|a) \rightarrow$ 有图因式分解
 $p(a, b, c) = p(a) \cdot p(b|a) \cdot p(c|a, b) \rightarrow$ Chain Rule

证明了图与概率独立性

若 a 被观测, 则路径被阻塞, $c \perp b$

② $a \rightarrow b, b \rightarrow c$
 $p(a, b, c) = p(a) \cdot p(b|a) \cdot p(c|a, b)$
 $\Rightarrow p(b) = p(b|a) \Rightarrow a \perp b$

可考察成之间关系

③ $a \rightarrow b, b \rightarrow c$

若 a 被观测, 路径是通的, 若 c 被观测, 路径是通的

若 b 被观测, 则路径被阻塞, $a \perp c$

①: tail to tail

②: head to tail

③: head to head



扫描全能王 创建

条件独立性 $X_A \perp X_C \perp X_B$

D-Separation: 对以上三种情况更通用

方法的描述 { a, c 若满足 ①, ②, 则 b 一定在 X_b 里
 ----- ③ ----- 不在 X_b 里, 且其后续节点都不会在 X_b 里

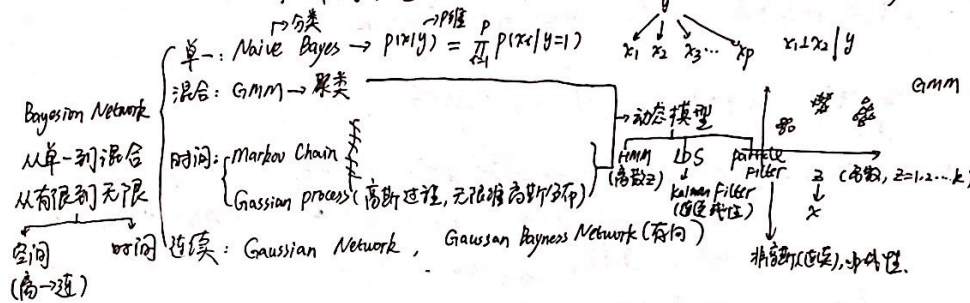


→ 全局 Markov property (全局马尔可夫性)

若 $A, B, C, x_p(A, C|B)$, 则 $X_A \perp X_C | X_B$

概率图模型 - 贝叶斯网络 - 例子(4)


Naive Bayes



概率图模型 - 马尔可夫随机场 (5)

① 全局马尔可夫 $X_A \perp X_C | X_B$

② 局部马尔可夫 $a \perp \{ \text{全-a-邻居} \} | \text{邻居}$



$a \perp \{e, f\} | \{b, c, d\}$

③ 成对马尔可夫 $X_i \perp X_j | X_{-ij}$ (i, j)
 排除邻居

以上是条件独立性体现的3个方面

① ⇔ ② ⇔ ③, 3者等价, 可互推出

图: 一个关于结点的集合, 集合的结点之间相互连接

最大图: 无法再往里加入任何一个结点

无向图的因子分解

$$p(x) = \frac{1}{Z} \prod_{i=1}^K \phi(x_{c_i})$$

$$Z = \sum_x \prod_{i=1}^K \phi(x_{c_i})$$

$$= \sum_{x_1, x_2, \dots, x_p} \prod_{i=1}^K \phi(x_{c_i})$$

x_{c_i} : 一个团对应随机变量的集合

Z : 归一化因子

图 vs. 条件独立性

如何对应?

???



扫描全能王 创建

概率图模型 - 马尔可夫随机场 (6)

(正)

Markov

① 全局

② 局部

③ 成对

① \Leftrightarrow ② \Leftrightarrow ③

因子分解

$$p(x) = \frac{1}{Z} \prod_{c \in \mathcal{C}} \psi(x_c)$$

\mathcal{C} : 最大团 \mathcal{X}_c : 最大团的随机变量集合

$\psi(x_c)$: 势函数, 必为正

$$Z = \sum_x \prod_{c \in \mathcal{C}} \psi(x_c) = \sum_{x_1} \sum_{x_2} \dots \sum_{x_p} \prod_{c \in \mathcal{C}} \psi(x_c)$$

$$\psi(x_c) = \exp\{-E(x_c)\} > 0$$

\hookrightarrow energy function

$\hookrightarrow p(x)$ 称为 Gibbs Distribution (Boltzmann Distribution)

① \Leftrightarrow ② \Leftrightarrow ③ \Leftrightarrow 因子分解 (对于最大团)

此为 Hammersley-Clifford 定理 \blacktriangle \rightarrow ①②③

最大熵原理 \Rightarrow 指数族分布 $\{p(x) = h(x) \cdot \exp\{\eta^T \phi(x) - A(\eta)\} = \frac{1}{Z(\eta)} \cdot h(x) \cdot \exp\{\eta^T \phi(x)\}$
(也叫 Gibbs 分布)

$$\text{而 } p(x) = \frac{1}{Z} \prod_{c \in \mathcal{C}} \psi(x_c) = \frac{1}{Z} \prod_{c \in \mathcal{C}} \exp\{-E(x_c)\} = \frac{1}{Z} \exp\left\{-\sum_{c \in \mathcal{C}} E(x_c)\right\}$$

Markov Random Field \Leftrightarrow Gibbs Distribution \Leftarrow 最大熵原理 [通过①定理]

概率图模型 - Inference (7)

Inference \rightarrow 求概率


联合概率 $p(x) = p(x_1, x_2, \dots, x_p)$

边缘概率 $p(x_i) = \sum_{x_1} \sum_{x_2} \dots \sum_{x_{i-1}} \sum_{x_{i+1}} \dots \sum_{x_p} p(x)$
(积分)

条件概率 $p(x_a | x_b), x = x_a \cup x_b$

(已知部分, 求另一部分) \rightarrow 求联合概率

MAP: $\hat{z} = \arg\max_z p(z|x) \propto \arg\max_z p(z, x)$
($p(z|x) = \frac{p(z, x)}{p(x)}$)



HMM 三大问题: \rightarrow 边缘概率

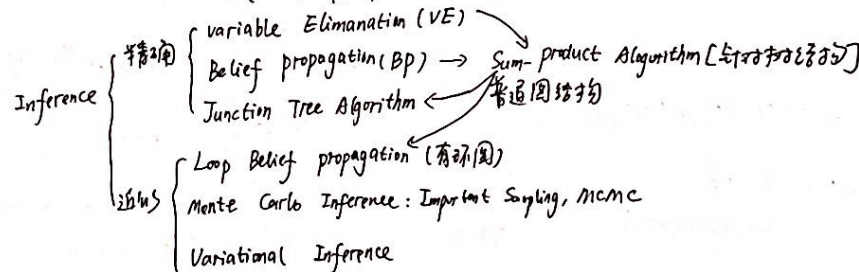
① Evaluation: $p(O) = \sum_i p(i, O) \Rightarrow$ 前向

② Learning: $\hat{\lambda}$

③ Decoding: $\hat{i} = \arg\max_i p(i|O)$
 $I \rightarrow$ Libras (OP)

①②③都是 Inference 问题

HMM: 特殊的 Dynamic Bayes Network



扫描全能王 创建

变量消除法 variable elimination \rightarrow 乘法分配律Tasks: Inference (给定 $p(x) = p(x_1, x_2, \dots, x_p)$)边缘概率 $p(x_1) = \sum_{x_2, \dots, x_p} p(x_1, x_2, \dots, x_p)$ 条件概率 $p(x_A | x_B)$ MAP $\tilde{x}_A = \arg \max_{x_A} p(x_A | x_B) = \arg \max_{x_A} p(x_A, x_B)$

缺点: ① 没有把计算存储下来, 每次算一次, 求c算一次, 重复计算.

② 消除次序 ordering \rightarrow NP-hard

找到最优次序 NP-hard

适用于节点少, 传播少, 但是是有序的基础.

$$a \rightarrow b \rightarrow c \rightarrow d$$

$$p(d) = \sum_{a,b,c} p(a,b,c,d)$$

(假设 a, b, c, d 是二值变量)
 $a, b, c, d \in \{0, 1\}$

$$= \sum_{a,b,c} p(a) \cdot p(b|a) \cdot p(c|b) \cdot p(d|c)$$

$$= p(a=0) \cdot p(b=0|a=0) \cdot p(c=0|b=0) \cdot p(d=0|c=0)$$

$$+ p(a=1) \cdot p(b=0|a=1) \cdot p(c=0|b=0) \cdot p(d=0|c=0)$$

$$+ \dots$$

$$+ p(a=1) \cdot p(b=1|a=1) \cdot p(c=1|b=1) \cdot p(d=1|c=1)$$

$$= 16 \cdot \text{因子积}$$

$$= \sum_{b,c} p(c|b) \cdot p(d|c) \cdot \sum_a p(a) \cdot p(b|a) \rightarrow \sum_a p(a,b) = p(b)$$

$$= \sum_c p(d|c) \cdot \sum_b p(c|b) \cdot \phi_a(b)$$

$$= \phi_b(c)$$

$$= \phi_c(d)$$

$$= \phi_d(e)$$

$$= \phi_e(f)$$

$$= \phi_f(g)$$

$$= \phi_g(h)$$

$$= \phi_h(i)$$

$$= \phi_i(j)$$

$$= \phi_j(k)$$

$$= \phi_k(l)$$

$$= \phi_l(m)$$

$$= \phi_m(n)$$

$$= \phi_n(o)$$

$$= \phi_o(p)$$

$$= \phi_p(q)$$

$$= \phi_q(r)$$

解决 VE 重复计算问题是.

组合起来(先求结果)

$$a \xrightarrow{m_{a \rightarrow b}} b \xrightarrow{m_{b \rightarrow c}} c \xrightarrow{m_{c \rightarrow d}} d \xrightarrow{m_{d \rightarrow e}} e \quad [\text{类似 HMM}]$$

$$p(a,b,c,d,e) = p(a) \cdot p(b|a) \cdot p(c|b) \cdot p(d|c) \cdot p(e|d)$$

$$p(e) = \sum_{a,b,c,d} p(a,b,c,d,e)$$

$$= \sum_{a,b,c,d} p(e|d) \cdot \sum_c p(d|c) \cdot \sum_b p(c|b) \cdot \sum_a p(a|b)$$

$$= \sum_{a,b,c,d} p(e|d) \cdot \sum_c p(d|c) \cdot \sum_b p(c|b) \cdot \sum_a p(a|b)$$

$$= \sum_{a,b,c,d} p(e|d) \cdot \sum_c p(d|c) \cdot \sum_b p(c|b) \cdot \sum_a p(a|b)$$

$$= \sum_{a,b,c,d} p(e|d) \cdot \sum_c p(d|c) \cdot \sum_b p(c|b) \cdot \sum_a p(a|b)$$

$$= \sum_{a,b,c,d} p(e|d) \cdot \sum_c p(d|c) \cdot \sum_b p(c|b) \cdot \sum_a p(a|b)$$

$$= \sum_{a,b,c,d} p(e|d) \cdot \sum_c p(d|c) \cdot \sum_b p(c|b) \cdot \sum_a p(a|b)$$

$$= \sum_{a,b,c,d} p(e|d) \cdot \sum_c p(d|c) \cdot \sum_b p(c|b) \cdot \sum_a p(a|b)$$

$$= \sum_{a,b,c,d} p(e|d) \cdot \sum_c p(d|c) \cdot \sum_b p(c|b) \cdot \sum_a p(a|b)$$

$$= \sum_{a,b,c,d} p(e|d) \cdot \sum_c p(d|c) \cdot \sum_b p(c|b) \cdot \sum_a p(a|b)$$

Belief propagation (9)

Chain \rightarrow Tree 有向 \rightarrow 无向 [无向树]

从信息角度考虑

$$p(a,b,c,d) = \frac{1}{2} \psi_a(a) \cdot \psi_b(b) \cdot \psi_c(c) \cdot \psi_d(d)$$

$$= \frac{1}{2} \psi_a(a) \cdot \psi_b(b) \cdot \psi_c(c) \cdot \psi_d(d)$$

$$= \frac{1}{2} \psi_a(a) \cdot \psi_b(b) \cdot \psi_c(c) \cdot \psi_d(d)$$

$$= \frac{1}{2} \psi_a(a) \cdot \psi_b(b) \cdot \psi_c(c) \cdot \psi_d(d)$$

$$= \frac{1}{2} \psi_a(a) \cdot \psi_b(b) \cdot \psi_c(c) \cdot \psi_d(d)$$

$$= \frac{1}{2} \psi_a(a) \cdot \psi_b(b) \cdot \psi_c(c) \cdot \psi_d(d)$$

$$= \frac{1}{2} \psi_a(a) \cdot \psi_b(b) \cdot \psi_c(c) \cdot \psi_d(d)$$

$$= \frac{1}{2} \psi_a(a) \cdot \psi_b(b) \cdot \psi_c(c) \cdot \psi_d(d)$$

$$= \frac{1}{2} \psi_a(a) \cdot \psi_b(b) \cdot \psi_c(c) \cdot \psi_d(d)$$

$$= \frac{1}{2} \psi_a(a) \cdot \psi_b(b) \cdot \psi_c(c) \cdot \psi_d(d)$$


$$= \frac{1}{2} \psi_a(a) \cdot \psi_b(b) \cdot \psi_c(c) \cdot \psi_d(d)$$



白板 (9)

Belief propagation (10)

(正)




$$m_{j \rightarrow i}(x_i) = \sum_{x_j} \psi_{ij} \prod_{k \in N(i)-i} m_{k \rightarrow j}(x_j) \quad \text{--- ①}$$

$$p(x_i) = \psi_i \prod_{k \in N(i)} m_{k \rightarrow i}(x_i) \quad \text{--- ②}$$

对于 ①式 $m_{j \rightarrow i} = \sum_{x_j} \psi_{ij} \prod_{k \in N(i)-i} m_{k \rightarrow j}$, 以左图为例 $m_{b \rightarrow a} = \sum_b \psi_{ab} \cdot \underbrace{\psi_b \cdot m_{c \rightarrow b} m_{d \rightarrow b}}_{\substack{\text{self} \quad \text{children}}}$

$\rho \rightarrow \text{belief}(b)$



$\therefore \begin{cases} \text{belief}(b) = \psi_b \cdot \text{Children} \\ m_{b \rightarrow a} = \sum_b \psi_{ab} \cdot \text{belief}(b) \end{cases}$

分两步, 可从信息汇总角度去理解。

$\text{belief}(b)$ 代表 b 点的总信息量, $m_{b \rightarrow a}$ 就是从 $b \rightarrow a$ 的信息量 + $\text{belief}(b)$ 自身信息量

正是因为求解过程中,

m_{ij} 多计算, \therefore 才有 BP 算法

BP = VE + Caching (缓存)

直接求 $m_{ij} \Rightarrow p(x_i)$
求过的遍历

BP (Sequential Implementation)

① get root \rightarrow 指定点都同意, a, c, d

② Collect message

for x_i in $NB(\text{root})$:

collect message (x_i)

③ Distribute message

for x_j in $NB(\text{root})$:

distribute message (x_j)


可得 m_{ij} for all $i, j \in V \rightarrow$ 节点

$\times (\psi_i p(x_i), i \in V)$

Max product (11) (12)

Belief propagation (树结构)

HMM 的 Decoding 问题是求隐状态序列最大



Decoding: $\hat{y} = \arg \max_{\hat{y}} P(\hat{y}|x)$

Viterbi (动态规划)

$$(\hat{a}, \hat{b}, \hat{c}, \hat{d}) = \arg \max_{a, b, c, d} p(x_a, x_b, x_c, x_d | E)$$

E 是观测到的其它节点,

一环套一环, Viterbi 思想

$$(\hat{x}_a^*, \hat{x}_b^*, \hat{x}_c^*, \hat{x}_d^*) = \arg \max_{x_a, x_b, x_c, x_d} p(x_a, x_b, x_c, x_d | E)$$

$$m_{j \rightarrow i}(x_i) = \sum_{x_j} \psi_{ij}(x_j) \psi_{ij}(x_i, x_j) \prod_{k \in N(i)-i} m_{k \rightarrow j}(x_j)$$

Max product

① BP 的改进 ② Viterbi 的推广

$$m_{j \rightarrow i} = \max_{x_j} \psi_{ij} \cdot \psi_{ij} \prod_{k \in N(i)-i} m_{k \rightarrow j} \quad [\text{把之前} \sum_{x_j} \text{用} \max_{x_j}]$$

x_j 是有一个状态, 找最大状态

[之前是对所有状态求和]

之前 Sum-product, 现在 Max-product, 其它不变。

$$m_{c \rightarrow b} = \max_{x_c} \psi_{c \rightarrow b}$$

关于 c 的函数

$$m_{d \rightarrow b} = \max_{x_d} \psi_{d \rightarrow b}$$

关于 d 的函数

$$m_{b \rightarrow a} = \max_{x_b} \psi_{b \rightarrow a} \cdot m_{c \rightarrow b} \cdot m_{d \rightarrow b}$$

关于 b 的函数

$$\max p(a, b, c, d) = \max_{x_a} \psi_a \cdot m_{b \rightarrow a}$$

关于 a 的函数

$$\hat{x}_a^*, \hat{x}_b^*, \hat{x}_c^*, \hat{x}_d^*$$



扫描全能王 创建

Factor Graph 因子图 (13)

(12)

BP只应用于树结构, 引入环后, 使用因子图.


有向图: $p(x) = \prod_i p(x_i | x_{pa(i)})$

无向图: $p(x) = \frac{1}{Z} \prod_{i=1}^K \phi_i(x_i)$
 最大团集合

道德图: 有向图 \rightarrow 无向图 (tree-like graph)
 (树) (引入环)

② 简便

因式分解本身对应
 一个特殊的因子图
 因子图: 看作对因式分解
 的更进一步分解




因子图 $x = x_1, x_2, \dots, x_p$

$$p(x) = \prod_s f_s(x_s)$$

s : 图的节点子集
 x_s : x 的随机变量子集

$f_s = f(a, b, c)$ 因子图不唯一

$$p(x) = f_1(a, b) + f_2(a, c) + f_3(b, c)$$



Moral Graph 道德图 (14)

产生原因: 想把有向图转为无向图.


因为更为通用 [令 $d_i = 1$ 如果 $x_i = 1$]

有向图: head-head (V结构) 一特殊

处理办法:

① $\forall x_i \in G$, 将 $parent(x_i)$ 两两相连


② 将 G 中有向边替换成无向边



$Sepl(A, B | C) \Leftrightarrow D-Sepl(A, B | C)$
 道德图 \nearrow 不证明了.

① $a \rightarrow b \rightarrow c$

$$p(a, b, c) = p(a) \cdot p(b|a) \cdot p(c|b)$$



②



$$p(a, b, c) = p(a) \cdot p(b|a) \cdot p(c|b)$$

③



$$p(a, b, c) = p(a) \cdot p(b) \cdot p(c|a, b)$$



(a, b, c 显然不是一个团 \rightarrow a, b 不连)



这是团!



扫描全能王 创建