

Inference { 精确推断
 近似推断 { 确定性 \rightarrow VI
 随机 \rightarrow MCMC

Monte Carlo Method: 基于采样的随机逼近方法
蒙特卡罗方法

Inference 推断主要任务: 求 $p(z|x) \rightarrow E_{p(z|x)}[f(z)]$

积分不好求, 所以用数值积分 $= \int p(z|x) f(z) dz$

采样 $\{z^{(1)}, z^{(2)}, \dots, z^{(N)}\} \sim p(z|x)$
 $\{f(z^{(1)}), f(z^{(2)}), \dots, f(z^{(N)})\}$

如何从复杂分布中采样?

② 重要性采样 Important sample.

不直接对 $p(z)$ 采样, 对 $q(z)$ 下的期望采样


$$E_{p(z)}[f(z)] = \int p(z) f(z) dz = \int \frac{p(z)}{q(z)} \cdot q(z) \cdot f(z) dz$$
$$= \int f(z) \cdot \frac{p(z)}{q(z)} \cdot q(z) dz \approx \frac{1}{N} \sum_{i=1}^N f(z_i) \cdot \left[\frac{p(z_i)}{q(z_i)} \right]$$

$z_i \sim q(z), i=1, \dots, N$

重要性采样变种

Sampling - Importance - Resampling

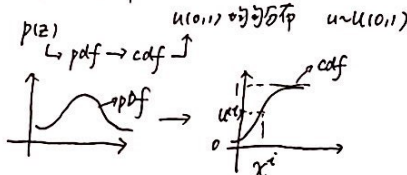
N 个样本



采样权重有高低, 那么每个样本点有 weight

再去采样 N 个样本点 \rightarrow 分两个阶段 \rightarrow 注重思想
内容较复杂

① 概率分布采样




* 计算机很容易生成 $u \sim U(0,1)$, 通过其生成 x^i

$x^{(i)} = \text{cdf}^{-1}(u^{(i)})$ 采样得到 N 个点
 $x^{(1)}, \dots, x^{(N)}$

问题: 由 pdf 求 cdf, 很可能求不出来, \therefore pdf 可能很复杂

② Rejection Sampling, 拒绝采样



$\forall z_i, m q(z_i) \geq p(z_i)$ 建议分布
对任意 z_i , 满足 m 是常数

前提: $p(z)$ 好采样, 有一个分布 $q(z)$ 好采样

采样应用接受率 α [落在阴影接受, xx 处拒绝]

$$\alpha = \frac{p(z^{(i)})}{m q(z^{(i)})}, 0 \leq \alpha \leq 1$$

算法流程 $z^{(i)} \sim q(z)$

$u \sim U(0,1)$

if $u \leq \alpha$, 接受 $z^{(i)}$

else 拒绝

为什么用 m , 因为不知道 $p(z)$ 是什么样, 故为了
保证 $q(z) \geq p(z)$, 求 m
常数 m



Monte Carlo Method: 基于随机采样的近似方法

pdf \rightarrow cdf (递增且值域在 $[0,1]$ 之间)

Markov Chain: 时间、状态都是离散的。


然后在数轴上采样, ... 参考上张纸

齐次 (time-homogeneous) Markov Chain:

$$p(x_{t+1} = x | x_1, x_2, \dots, x_t) = p(x_{t+1} | x_t)$$

$P \rightarrow$ 状态转移矩阵 $[P_{ij}]$

$$P_{ij} = p(x_{t+1} = j | x_t = i)$$



$$x \xrightarrow{\pi_t(x)} x^{*}$$

$$\text{表达} \rightarrow \pi_{t+1}(x^{*}) = \int \pi_t(x) \cdot p(x \rightarrow x^{*}) dx$$

↓
转移概率

▲ ①

平稳分布, 假设存在 $\pi = [\pi_1, \pi_2, \dots, \pi_n]$ 使得

$$\sum_{i=1}^n \pi_i = 1$$

$$\pi(x^{*}) = \int \pi(x) \cdot p(x \rightarrow x^{*}) \cdot dx, \text{ 用 } \pi$$

$\{\pi_k\}$ 是 $\{x_t\}$ 的平稳分布 \Rightarrow 即 π_k 同分布?

▲ ②

Detail Balance (细致平衡) \rightarrow 来回概率一样

若满足②, 则推出①平稳分布

$$\pi(x) \cdot p(x \rightarrow x^{*}) = \pi(x^{*}) \cdot p(x^{*} \rightarrow x)$$

若一个分布满足②, 则一定满足①, 反之不一定

----- ①, 不一定 ②

把 π 与 p 联系起来

平稳分布

或

链转移

矩阵

$$\int \pi(x) p(x \rightarrow x^{*}) dx$$

$$= \int \pi(x^{*}) p(x^{*} \rightarrow x) dx$$

$$= \pi(x^{*}) \int p(x^{*} \rightarrow x) dx = \pi(x^{*})$$

= 1



自反 (13)

MC MC - Metropolis - Hastings 算法

$$\text{任务: 推导出后验概率 } p(z) \rightarrow E_{p(z)}[f(z)] = \int f(z)p(z)dz$$

$$z^{(1)}, z^{(2)}, \dots, z^{(N)} \sim p(z) \Rightarrow \text{通过采样} \approx \frac{1}{N} \sum_{i=1}^N f(z^{(i)})$$

由于直接通过 $p(z)$ 采样困难, 所以提出 MCMC, 构造马尔可夫链, $p(z)$ 看作 $\pi(x)$, 让其平稳分布

那么问题变成 $x \rightarrow x^*$, $x^* \rightarrow x$ 的转移矩阵是什么, 才可以满足平稳分布的不等式.

p_{ij} 怎么求. ▲

从马尔可夫链任意取一个 $Q = [Q_{ij}]$, 那么 $p(z) \cdot Q(z \rightarrow z^*) \neq p(z^*) \cdot Q(z^* \rightarrow z)$

$$\text{定义一个接受率 } \alpha(z, z^*), \text{ 使得 } \underbrace{p(z) \cdot Q(z \rightarrow z^*) \cdot \alpha(z, z^*)}_{\alpha(z^*, z)} = \underbrace{p(z^*) \cdot Q(z^* \rightarrow z) \cdot \alpha(z^*, z)}_{p(z^* \rightarrow z)}$$

$$\text{那么 } \alpha(z, z^*) = \min\left(1, \frac{\underbrace{p(z^*) \cdot Q(z^* \rightarrow z)}_{\hookrightarrow Q(z^*|z)} \cdot \underbrace{p(z \rightarrow z^*)}_{\hookrightarrow Q(z|z^*)}}{p(z) \cdot Q(z \rightarrow z^*)}\right) \quad \text{①}$$

验证 ① 式,

$$\begin{aligned} p(z) \cdot Q(z \rightarrow z^*) \cdot \alpha(z, z^*) &= p(z) \cdot Q(z \rightarrow z^*) \cdot \min(\dots) \stackrel{\text{①式}}{=} \min(p(z) \cdot Q(z \rightarrow z^*), p(z^*) \cdot Q(z^* \rightarrow z)) \\ &= p(z^*) \cdot Q(z^* \rightarrow z) \cdot \min\left(1, \frac{p(z) \cdot Q(z \rightarrow z^*)}{p(z^*) \cdot Q(z^* \rightarrow z)}\right) \\ &= p(z^*) \cdot Q(z^* \rightarrow z) \cdot \alpha(z^*, z) \end{aligned}$$

\therefore 只要满足 ① 式, 则可以满足 Detailed Balance $\pi(x) \cdot p(x \rightarrow x^*) = \pi(x^*) \cdot p(x^* \rightarrow x)$ \nearrow 上一个样本

以上就是 Metropolis - Hastings 算法 $u \sim U(0, 1)$ 均匀分布 $z^* \sim Q(z|z^{(t-1)})$

$$\alpha = \min\left(1, \frac{p(z^*) \cdot Q(z^* \rightarrow z)}{p(z) \cdot Q(z \rightarrow z^*)}\right), \text{ if } u \leq \alpha, z^{(t)} = z^* \text{ (直接接受)}, \text{ else } z^{(t)} = z^{(t-1)}, \text{ (取上一个样本)}$$

MC MC \rightarrow 吉布斯采样

本质上还是 MH 采样. 特殊的 MH 采样. 高维度采样, 一维一维采 (固定其它维度) $z_i \sim p(z_i|z_{-i})$

假设 3 维, $p(z) = p(z_1, z_2, z_3)$. $z_1^{(0)}, z_2^{(0)}, z_3^{(0)}$, 那么 $t+1$, $z_1^{(t+1)} \sim p(z_1|z_2^{(t)}, z_3^{(t)})$

$z_2^{(t+1)} \sim p(z_2|z_1^{(t+1)}, z_3^{(t)})$, $z_3^{(t+1)} \sim p(z_3|z_1^{(t+1)}, z_2^{(t+1)})$

\hookrightarrow 采样过的

\hookrightarrow 采样过的

验证 Gibbs 是 MH - 特例

$$\frac{p(z^*) \cdot Q(z^* \rightarrow z)}{p(z) \cdot Q(z \rightarrow z^*)} = \frac{p(z_1^*|z_2^*, z_3^*) \cdot p(z_2^*|z_1^*, z_3^*) \cdot p(z_3^*|z_1^*, z_2^*)}{p(z_1|z_2, z_3) \cdot p(z_2|z_1, z_3) \cdot p(z_3|z_1, z_2)} \stackrel{\text{相消}}{=} 1$$

$\therefore \alpha = 1$, 是特殊的 MH 算法



扫描全能王 创建

一. 采样动机(为什么要采样) ① 采样本身就是常见的做法 ② 求积分或求和, 复杂求和/积分有解析解
一般都用MCMC方法采样逼近.


$$\int p(x) \cdot f(x) dx = E_{p(x)}[f(x)]$$

$$x^{(1)}, x^{(2)}, \dots, x^{(n)} \sim p(x) \text{ 采样}$$

$$\approx \frac{1}{n} \sum_{i=1}^n f(x^{(i)})$$

二. 什么样的样本才是好的样本?

① 样本趋向于高概率区域



其它区域

② 样本之间相互独立, 无相关性
强, 代表不了全部样本的分布.

$x^{(1)}, x^{(2)}, \dots, x^{(n)}$ 相关

三. 采样是困难的.

① partition function is intractable $p(x) = \frac{1}{Z} \tilde{p}(x)$

\hookrightarrow 归一化不可行, 高维时


② high dimension 不可行

因此提出 Rejection Sampling / Importance Sampling. 引入 $q(x)$, 逼近 $p(x)$.

MCMC \rightarrow 马尔可夫链 Monte Carlo

MCMC原理: 构造马尔可夫链(状态: 经过若干步后, 会收敛到目标平稳分布) 证明平稳分布:

状态空间: $\{1, 2, \dots, k\}$ 在 m 之后, 是平稳分布



$$q^{(0)}(x) \quad x \quad \begin{matrix} 1 & 2 & 3 & \dots & k \\ q^{(0)}(x) & q^{(1)}(x) & q^{(2)}(x) & \dots & q^{(k)}(x) \end{matrix} \quad \sum_{i=1}^k q^{(i)}(x) = 1$$

m 步之前, 其概率分布不同.

m 之后 $p(q^{(m)}(x)) = p(q^{(m+1)}(x)) = \dots$ 相同

其值为 $\frac{1}{k}$ $\frac{x}{k} \quad \frac{1}{k} \quad \frac{2}{k} \quad \dots \quad \frac{k}{k}$ (均匀分布)

收敛情况: 收敛后, 其概率分布逼近 $p(x)$

状态转移矩阵: (随机矩阵)

$$Q = \begin{pmatrix} Q_{11} & Q_{12} & \dots & Q_{1k} \\ Q_{21} & Q_{22} & \dots & Q_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ Q_{k1} & Q_{k2} & \dots & Q_{kk} \end{pmatrix} \quad \begin{matrix} \text{行和}=1 \\ \text{列和}=1 \end{matrix}$$

$$q^{(t+1)}(x=j) = \sum_{i=1}^k q^{(t)}(x=i) Q_{ij} \quad \text{要求求和}$$

$$q^{(t+1)} = (q^{(t)}(x=1), q^{(t)}(x=2), \dots, q^{(t)}(x=k))$$

而已知①式:

$$q^{(t+1)} = \left(\sum_{i=1}^k q^{(t)}(x=i) Q_{i1}, \sum_{i=1}^k q^{(t)}(x=i) Q_{i2}, \dots, \sum_{i=1}^k q^{(t)}(x=i) Q_{ik} \right)$$

$$= q^{(t)} \cdot \begin{pmatrix} Q_{11} & Q_{12} & \dots & Q_{1k} \\ Q_{21} & Q_{22} & \dots & Q_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ Q_{k1} & Q_{k2} & \dots & Q_{kk} \end{pmatrix} \quad \text{②}$$

$$q^{(t+1)} = q^{(t)} \cdot Q$$

随机矩阵: 将矩阵的绝对值求和为1

$$Q = A \cdot \Lambda \cdot A^{-1} \quad \text{[特征分解]}$$

$$\text{其中 } \Lambda = \begin{pmatrix} \lambda_1 & & \\ & \lambda_2 & \\ & & \ddots \\ & & & \lambda_k \end{pmatrix}, \quad |\lambda_i| \leq 1, \text{ for } i=1 \dots k$$

不妨假设有一个 $\lambda_i = 1$, 其它 $\lambda_i < 1$

$$\text{则②式} = q^{(1)} \cdot (A \cdot \Lambda^t \cdot A^{-1}) \quad \text{求逆} \quad q^{(1)} \cdot A \cdot \Lambda^t \cdot A^{-1}$$

存在足够大的 m , s.t. $\Lambda^m = \begin{pmatrix} 1 & & \\ & 0 & \\ & & \ddots \\ & & & 0 \end{pmatrix}$

$$q^{(m+1)} = q^{(1)} \cdot A \cdot \Lambda^m \cdot A^{-1}, \quad q^{(m+2)} = q^{(1)} \cdot \Lambda \cdot \Lambda^m \cdot A^{-1} = q^{(1)} \cdot \Lambda^m$$

$$\text{又 } \Lambda^m = \begin{pmatrix} 1 & & \\ & 0 & \\ & & \ddots \\ & & & 0 \end{pmatrix} \quad \therefore \Lambda^{m+1} = \Lambda^m \Rightarrow q^{(m+2)} = q^{(m+1)}$$

当 $t > m$ 时, $q^{(m+1)} = q^{(m+2)} = \dots = q^{(m+t)} \Rightarrow$ 平稳分布了

Rejection Sampling } $q(x)$ 与 $p(x)$ 接近
Importance Sampling } 且 $q(x)$ 简单易采样

MCMC { MH
Gibbs




白板(13)

MC MC - 采样思路及面临困难

反

状态空间: $\{1, 2, \dots, k\}$
 状态转移矩阵: $Q = [Q_{ij}]_{k \times k}$ } 离散
 假定进入 m 步后, 进入平稳分布。

MCMC 是一套方法论, 具体方法很多。
 最基础的是 HM, Gibbs



MCMC: 利用 Markov Chain 收敛于平稳分布。
 设计 Q , 使得平稳分布 \approx 目标分布 $p(x)$, 任意分布, 包括目标分布。

拒绝采样和重要性采样在高维空间, 根据找到 $q(x) \approx p(x)$ 。

初始状态 $q^{(1)}(x)$ 可以从状态空间任取, 只要收敛于平稳分布与 Q 有关, 与初始状态 $q^{(1)}(x)$ 无关。

从 $1 \sim m$ 步, 称之为 burn-in (烧周期), 所花的时间 mixing time。

关注设计 Q , 而非在高维空间采样

MCMC 问题: ① 无法判断收敛于平稳分布的时间, 理论只保证了收敛性。

→ 只能靠 xx 步后是否收敛

② 混合时间 mixing time 过长 / 不混合 / 不收敛 (发散) → $p(x)$ 太复杂, 高维造成, 且维度之间相关性

③ 好的采样: 要相互独立, 但是 m 与 $m+1$ 一定相关 (马氏链)。实际上在进入平稳分布后, 相关性。

④ 最大问题: 处理多峰 (Gibbs)

一维高斯分布 (单峰) vs. GMM (多峰)



① 多峰会采在一个峰值上, 无法越过低概率区域。

② 多峰随机采样难度大, 混合失败。

有很多 MCMC 会解决上述问题 [高维, 陡峭]



扫描全能王 创建